

به نام خداوند جان و خرد



دانشگاه تهران

دانشکده فنی

دانشکده مهندسی برق و کامپیوتر

# پروژه نهایی یادگیری ماشین

## گزارش اولیه

شماره دانشجویی: ۸۱۰۱۰۲۱۲۹

نام و نام خانوادگی: علی خرم فر

شماره دانشجویی: ۸۱۰۱۰۲۳۵۹

نام و نام خانوادگی: زهرا فیض اله زاده

شماره دانشجویی: ۸۱۰۱۰۲۳۰۱

نام و نام خانوادگی: زینب یزدانی

خردادماه ۱۴۰۳

# فهرست مطالب

۱	مقدمه ای بر تصویرسازی حرکتی
۱-۱	تعریف تصویرسازی حرکتی
۱-۲	کاربردهای تصویرسازی حرکتی
۱	توان بخشی عصبی
۲	فعالیت های ورزشی
۲	رابط مغز و کامپیوتر
۲	پژوهش در علوم شناختی
۲	۱-۳ کاربرد تصویرسازی حرکتی در رابط مغز و کامپیوتر
۳	مزایای استفاده از تصویرسازی حرکتی در BCI
۳	بهبود عملکرد BCI با تصویرسازی حرکتی
۴	۲ چالش های تصویرسازی حرکتی
۴	۲-۱ چالش های اصلی تصویرسازی حرکتی
۴	تنوع فردی یا Individual variability در سیگنال های EEG
۴	نویز و اختلالات محیطی
۴	پیچیدگی و زمان بر بودن فرایند کالیبراسیون
۴	کاربردهای محدود در افراد مبتلا به BCI Illiteracy
۵	۲-۲ راه حل های بالقوه و تحقیقات جاری برای غلبه بر چالش ها
۵	تنوع فردی یا Individual variability در سیگنال های EEG
۵	نویز و اختلالات محیطی
۵	پیچیدگی و زمان بر بودن فرایند کالیبراسیون
۶	کاربردهای محدود در افراد مبتلا به BCI Illiteracy
۷	۳ پیش پردازش سیگنال های EEG
۷	۳-۱ اهمیت پیش پردازش سیگنال های EEG در تصویرسازی حرکتی
۷	۳-۲ فیلتر میان گذر (حوزه فرکانس)
۸	تجزیه و تحلیل تصور حرکتی با استفاده از باندهای فرکانس EEG
۹	۳-۳ فیلترهای فضایی
۹	Common Average Reference (CAR)
۱۰	Laplacian Filter

۱۱.....Principal Component Analysis (PCA)

۱۳.....Independent Component Analysis (ICA)

۱۴.....Minimum Norm Estimation (MNE)

۱۶..... ۴\_ تکنیک‌های استخراج ویژگی

۱۶..... ۴-۱\_ تکنیک‌های مختلف استخراج ویژگی

۱۶..... روش‌های حوزه زمان

۱۸..... روش‌های حوزه فرکانس

۱۹..... روش‌های حوزه زمان-فرکانس

۲۲..... روش‌های فضایی

۲۵..... ۵\_ مراجع

# ۱- مقدمه ای بر تصویرسازی حرکتی

## ۱-۱- تعریف تصویرسازی حرکتی

تصویرسازی حرکتی<sup>۱</sup> به فرایند تصور ذهنی حرکت، مانند حرکت دادن انگشتان دست، بدون انجام فیزیکی آن اشاره دارد. در این حالت، فرد بدون انجام حرکت واقعی، تصور می‌کند که یک حرکت خاص را انجام می‌دهد. این فرایند باعث ایجاد الگوهای خاصی از فعالیت مغزی می‌شود که می‌توان آن‌ها را با استفاده از الکترودهای EEG<sup>۲</sup> ثبت و تجزیه و تحلیل کرد. این ابزار، به طور گسترده‌ای در زمینه‌های مختلفی از جمله توان بخشی عصبی<sup>۳</sup>، فعالیت‌های ورزشی، و رابط مغز و کامپیوتر (BCI)<sup>۴</sup> مورد استفاده قرار می‌گیرد.

تصویرسازی حرکتی در بسیاری از تحقیقات علوم شناختی و مهندسی پزشکی مورد مطالعه قرار گرفته است. در رابط‌های مغز و کامپیوتر، تصویرسازی حرکتی به عنوان یکی از مؤثرترین روش‌ها برای کنترل دستگاه‌های مختلف از طریق سیگنال‌های مغزی شناخته شده است (Pfurtscheller & Neuper, 2001).

## ۱-۲- کاربردهای تصویرسازی حرکتی

تصویرسازی حرکتی به دلیل تأثیرات قابل توجه آن بر فعالیت‌های مغزی و کاربردهای گسترده‌ای که در حوزه‌های مختلف دارد، اهمیت ویژه‌ای دارد. این تکنیک نه تنها در زمینه‌های توان بخشی و آموزش ورزشی، بلکه در توسعه رابط مغز و کامپیوتر نقش کلیدی ایفا می‌کند. در این قسمت از گزارش به برخی از دلایل اصلی اهمیت تصویرسازی حرکتی با توجه به کاربردهای مختلف آن اشاره می‌کنیم:

### توان بخشی عصبی

تصویرسازی حرکتی به عنوان یک ابزار مؤثر در توان بخشی عصبی برای بیمارانی که دچار آسیب‌های مغزی یا سکت شده‌اند، استفاده می‌شود (Sharma et al., 2006). این تکنیک می‌تواند به بازیابی عملکرد حرکتی کمک کرده و نقش مهمی در فرایند بازآموزی مغز ایفا کند. پژوهش‌های اخیر نشان می‌دهد که تمرینات تصویرسازی حرکتی می‌تواند انعطاف پذیری عصبی یا پلاستیسیته<sup>۵</sup> عصبی را تحریک کرده و به بهبود عملکردهای حرکتی کمک کند (Pfurtscheller & Neuper, 2001).

---

<sup>1</sup> Motor Imagery

<sup>2</sup> Electroencephalography

<sup>3</sup> Neurorehabilitation

<sup>4</sup> Brain-computer interface

<sup>5</sup> plasticity

## فعالیت‌های ورزشی

تصویرسازی حرکتی به‌عنوان یک روش مؤثر برای بهبود عملکرد فعالیت‌های ورزشی مورد استفاده قرار می‌گیرد. ورزشکاران می‌توانند از این تکنیک برای تمرین ذهنی حرکات پیچیده و بهبود هماهنگی حرکات استفاده کنند. مطالعات نشان داده‌اند که تصویرسازی حرکتی می‌تواند باعث بهبود عملکرد فیزیکی جسمانی و افزایش اعتماد به نفس در ورزشکاران شود (Guillot and Collet 2008). از طرفی تصویرسازی حرکتی می‌تواند به کاهش اضطراب و استرس کمک کرده و ورزشکاران و افراد مختلف با استفاده از آن آرامش ذهنی بیشتری پیدا کنند.

## رابط مغز و کامپیوتر

در سیستم‌های BCI، تصویرسازی حرکتی به‌عنوان یکی از مؤثرترین روش‌ها برای کنترل دستگاه‌های مختلف از طریق سیگنال‌های مغزی استفاده شده و امکان کنترل پروتزهای عصبی و دستگاه‌های کمکی را برای افرادی که دارای ناتوانی‌های حرکتی هستند، فراهم می‌کند (Neuper & Pfurtscheller, 2010). پژوهش‌های مختلف نشان می‌دهند که استفاده از تصویرسازی حرکتی در BCI، می‌تواند دقت و کارایی این سیستم‌ها را به طور قابل توجهی افزایش دهد (Jeunet et al., 2016).

## پژوهش در علوم شناختی<sup>۱</sup>

یکی دیگر از کاربردهای تصویرسازی حرکتی استفاده از آن به‌عنوان یک ابزار تحقیقاتی برای مطالعه مکانیسم‌های عصبی و شناختی است و از این طریق به پژوهشگران کمک می‌کند تا فرایندهای مغزی مرتبط با حرکت و تصور حرکت را بهتر درک کنند (Munzert et al., 2009).

## ۳-۱\_ کاربرد تصویرسازی حرکتی در رابط مغز و کامپیوتر

همان‌طور که در بخش قبل اشاره شد، رابط‌های مغز و کامپیوتر یا BCI سیستم‌هایی هستند که به افراد امکان می‌دهند تا از طریق فعالیت‌های مغزی خود، دستگاه‌های خارجی را کنترل کنند. استفاده از تصویرسازی حرکتی در این ابزار نقش حیاتی در بهبود کیفیت زندگی افراد دارای ناتوانی‌های حرکتی داشته

---

<sup>۱</sup> Cognitive science

و به توسعه فناوری‌های جدید کمک می‌کند. مقالات و پژوهش‌های متعددی نشان داده‌اند که تصویرسازی حرکتی می‌تواند عملکرد سیستم‌های BCI را بهبود بخشیده و به افراد استفاده‌کننده از آن کمک کند تا استقلال بیشتری در زندگی روزمره خود داشته باشند.

### مزایای استفاده از تصویرسازی حرکتی در BCI

افراد با ناتوانی‌های حرکتی مانند پاراپلژی<sup>۱</sup> (فلج کامل پاها و تنه) یا تتراپلژی<sup>۲</sup> (فلج هر چهار اندام بدن) می‌توانند با استفاده از تصویرسازی حرکتی و سیستم‌های BCI دستگاه‌های کمکی مانند ویلچرها یا ربات‌های پروتز را کنترل کنند. همچنین استفاده از تصویرسازی حرکتی می‌تواند دقت و قابلیت اطمینان سیستم‌های BCI را افزایش دهد. از طرفی استفاده از EEG برای ثبت سیگنال‌های مرتبط با تصویرسازی حرکتی یک روش غیرتهاجمی است که نیازی به جراحی یا وارد کردن الکتروود به داخل مغز ندارد.

### بهبود عملکرد BCI با تصویرسازی حرکتی

استفاده از فیلترهای مکانی مانند CSP<sup>۳</sup> می‌تواند به بهبود تمایز بین سیگنال‌های مختلف تصویرسازی حرکتی کمک کند. این فیلترها به استخراج ویژگی‌های مرتبط و کاهش نویز سیگنال‌ها کمک می‌کنند که در بخش‌های بعدی گزارش به طور کامل بررسی می‌شود. همچنین استفاده از الگوریتم‌های یادگیری ماشین مانند SVM<sup>۴</sup>، KNN<sup>۵</sup>، و شبکه‌های عصبی می‌تواند به بهبود طبقه‌بندی سیگنال‌های تصویرسازی حرکتی و افزایش دقت سیستم‌های BCI کمک کند (Blankertz et al., 2006).

---

<sup>۱</sup> Paraplegia

<sup>۲</sup> Tetraplegia

<sup>۳</sup> Common Spatial Patterns

<sup>۴</sup> Support Vector Machine

<sup>۵</sup> K-Nearest Neighbors

## ۲\_ چالش‌های تصویرسازی حرکتی

اگرچه تصویرسازی حرکتی به‌عنوان یکی از روش‌های مؤثر در تحقیقات علوم‌شناختی است، با این حال، استفاده از این ابزار با چالش‌های متعددی همراه است که باید شناسایی و مورد بررسی قرار گیرند تا بتوان از آن به طور مؤثر و کارآمد استفاده کرد. در این بخش، به شناسایی و توضیح چالش‌های اصلی که در تحقیقات و کاربردهای تصویرسازی حرکتی وجود دارد، می‌پردازیم.

### ۲-۱\_ چالش‌های اصلی تصویرسازی حرکتی

#### تنوع فردی یا Individual variability در سیگنال‌های EEG

یکی از بزرگ‌ترین چالش‌ها در تصویرسازی حرکتی، تنوع فردی در سیگنال‌های EEG است. سیگنال‌های مغزی هر فرد منحصر به فرد بوده و الگوهای مختلفی از فعالیت مغزی را نشان می‌دهند. این تفاوت‌ها می‌توانند باعث کاهش دقت و قابلیت اطمینان سیستم‌های BCI شوند.

#### نویز و اختلالات محیطی

سیگنال‌های EEG به‌شدت تحت تأثیر نویزها و اختلالات محیطی قرار می‌گیرند. حرکت عضلات، فعالیت الکتریکی سایر دستگاه‌ها و تغییرات محیطی می‌توانند سیگنال‌های EEG را آلوده کرده و باعث کاهش دقت سیستم‌های BCI شوند.

#### پیچیدگی و زمان‌بر بودن فرایند کالیبراسیون

فرایند کالیبراسیون سیستم‌های BCI مبتنی بر تصویرسازی حرکتی می‌تواند زمان‌بر و پیچیده باشد. این فرایند نیاز به جمع‌آوری و تجزیه و تحلیل تعداد زیادی از داده‌های EEG دارد تا مدل‌ها بتوانند با دقت کافی عمل کنند.

#### کاربردهای محدود در افراد مبتلا به BCI Illiteracy

برخی از افراد قادر به تولید سیگنال‌های مغزی قابل تشخیص در حین تصویرسازی حرکتی نیستند، وضعیتی که به‌عنوان BCI Illiteracy شناخته می‌شود. این مسئله می‌تواند مانع از استفاده گسترده از BCI در بین افراد مختلف شود.

## ۲-۲. راه‌حل‌های بالقوه و تحقیقات جاری برای غلبه بر چالش‌ها

### تنوع فردی یا Individual variability در سیگنال‌های EEG

استفاده از روش‌های یادگیری ماشین انطباقی و تکنیک‌های شخصی‌سازی مدل‌ها می‌تواند به کاهش تأثیر تنوع فردی در سیگنال‌های EEG کمک کند. این روش‌ها شامل تنظیم پارامترهای مدل برای هر فرد به طور جداگانه و استفاده از داده‌های اولیه برای آموزش مدل‌های انطباقی است. (Fazli et al., 2009) همچنین ایجاد و استفاده از دیتاست‌های بزرگ و متنوع که شامل داده‌های EEG از تعداد زیادی افراد مختلف است، می‌تواند به بهبود دقت و قابلیت تعمیم مدل‌ها کمک کند.

### نویز و اختلالات محیطی

پیش‌پردازش داده‌ها مانند استفاده از فیلترهای مکانی و زمانی، روش‌های ICA<sup>۱</sup> و روش‌های حذف نویز می‌توانند به کاهش نویز و بهبود کیفیت سیگنال‌های EEG کمک کنند. از طرفی استفاده از الکترودهای EEG با کیفیت بالا که دارای مقاومت کم و حساسیت بالا هستند می‌تواند به کاهش نویز و افزایش دقت سیگنال‌ها کمک کند (McFarland & Wolpaw, 2011).

### پیچیدگی و زمان بر بودن فرایند کالیبراسیون

استفاده از روش‌های یادگیری انتقالی<sup>۲</sup> و یادگیری چندوظیفه‌ای<sup>۳</sup> برای کاهش زمان و پیچیدگی کالیبراسیون کمک‌کننده است. برای این کار می‌توان از مدل‌های از پیش آموزش‌دیده<sup>۴</sup> شده استفاده کرد (He

---

<sup>۱</sup> Independent Component Analysis

<sup>۲</sup> Transfer learning

<sup>۳</sup> Multi-task learning

<sup>۴</sup> Pre-Trained Model



(Wu, 2019) & همچنین توسعه مدل‌هایی که با داده‌های کمتری قادر به کالیبراسیون هستند و به سرعت به دقت بالایی دست می‌یابند، می‌تواند به حل این چالش کمک کند.

### کاربردهای محدود در افراد مبتلا به BCI Illiteracy

برای حل این مشکلات ایده‌ها و روش‌های مختلفی ارائه شده است. از جمله استفاده از سیگنال‌های زیستی دیگر مانند EMG<sup>۱</sup> یا EOG<sup>۲</sup> به عنوان مکمل یا جایگزین برای سیگنال‌های EEG در سیستم‌های BCI می‌تواند منجر به بهبود کارایی و دقت این سیستم‌ها شود (Fatourehchi et al., 2007). از طرفی توسعه روش‌های آموزشی بهتر و برنامه‌های تمرینی برای کاربران می‌تواند به کاهش مشکلات BCI Illiteracy کمک کند. به طور کلی می‌توان با انجام تحقیقات بیشتر برای درک عوامل مؤثر بر BCI Illiteracy و توسعه روش‌های جدید برای شناسایی و کاهش مشکلات ناشی از آن، برای غلبه بر این چالش اشاره کرد.

---

<sup>۱</sup> Electromyography

<sup>۲</sup> Electrooculography

## ۳- پیش‌پردازش سیگنال‌های EEG

پیش‌پردازش سیگنال‌های EEG یک مرحله حیاتی در تحلیل و تفسیر این سیگنال‌ها است، خصوصاً در زمینه تصویرسازی حرکتی که شامل تجسم حرکات بدون اجرای فیزیکی آن‌ها است.

### ۳-۱- اهمیت پیش‌پردازش سیگنال‌های EEG در تصویرسازی حرکتی

همان‌طور که در قسمت‌های قبل ذکر شد، تصویرسازی حرکتی به‌عنوان یک ابزار قدرتمند در توسعه رابط‌های مغز-کامپیوتر و توان‌بخشی عصبی مورد استفاده قرار می‌گیرد. با پیش‌پردازش صحیح، می‌توان نویزها و اختلالات موجود در سیگنال را که در قسمت چالش‌ها بیان شدند، با استفاده از فیلترهای مکانی و فرکانسی و روش‌های حذف نویز کاهش داده و اطلاعات مفیدتر و دقیق‌تری از فعالیت‌های مغزی استخراج کرد. این امر به بهبود عملکرد الگوریتم‌های طبقه‌بندی و افزایش دقت و کارایی سیستم‌های BCI کمک می‌کند.

با انجام تصور حرکتی، یک سری رخدادهایی در مغز اتفاق می‌افتد، دانستن اینکه این رخدادها در چه باندهای فرکانسی و چه نواحی از مغز اتفاق می‌افتند، بسیار مهم است. براین اساس، در این مرحله از انواع فیلترهای مکانی و فرکانسی جهت کاهش نویز سیگنال و source localization استفاده می‌شود.

### ۳-۲- فیلتر میان‌گذر (حوزه فرکانس)

پس از جمع‌آوری داده‌ها، یک مرحله پیش‌پردازش برای حذف نویز و آرتیفکت<sup>۱</sup> از سیگنال‌های EEG خام به‌منظور کاهش تأثیر آنها بر کارایی مراحل استخراج ویژگی و طبقه‌بندی انجام می‌شود. در پردازش سیگنال EEG، باندهای فرکانسی مختلفی وجود دارد که همه آنها مطلوب و مفید نیست. همچنین برخی نویزها و اختلالات مانند برق شهر نیز وجود دارند که روی سیگنال سوار شده‌اند؛ بنابراین لازم است مفیدترین مولفه‌های سیگنال شناسایی و استفاده شوند. EOG<sup>۲</sup> و EMG<sup>۳</sup> آرتیفکت‌های رایجی هستند که به دلیل حرکات چشم و عضلات با سیگنال‌های EEG تداخل می‌کنند. در این راستا فیلترهای میان‌گذر در بازه ۸ تا ۳۰ هرتز برای جداسازی باندهای فرکانسی خاص، از جمله باندهای مو<sup>۴</sup> و بتا<sup>۵</sup> در سیگنال‌های EEG که اطلاعات مهمی در مورد فعالیت‌های ذهنی و حرکتی فرد ارائه می‌دهند استفاده می‌شوند. این باندهای فرکانسی با فعالیت‌های

<sup>۱</sup> Artifact

<sup>۲</sup> Electrooculography

<sup>۳</sup> Electromyography

<sup>۴</sup> mu

<sup>۵</sup> beta

مختلف مغزی ارتباط مستقیمی دارند و می‌توانند اطلاعات مهمی در مورد وضعیت مغزی و فعالیت‌های حرکتی فراهم کنند.

با حذف نویزهای فرکانس پایین (مانند حرکت چشم و نویزهای محیطی) و نویزهای فرکانس بالا (مانند فعالیت عضلانی غیرمرتبط)، این فیلترها به تحلیل دقیق‌تر سیگنال‌های EEG کمک می‌کنند و استخراج ویژگی‌های مرتبط با حالت‌های مختلف ذهنی و فعالیت‌های حرکتی را تسهیل می‌کنند. این امر به‌ویژه در کاربردهای تصویرسازی حرکتی و رابط‌های مغز-کامپیوتر (BCI) بسیار حیاتی است (Alizadeh et al., 2023).

### تجزیه و تحلیل تصور حرکتی با استفاده از باندهای فرکانس EEG

- باند مو (۸-۱۳ هرتز): این باند فرکانسی در نواحی حسی-حرکتی مغز، به‌ویژه در ناحیه مرکزی یا C3 و C4، مشاهده می‌شود. باند مو با فعالیت‌های حرکتی و تصویرسازی حرکتی مرتبط است و در زمان استراحت عضلات یا تجسم حرکتی کاهش می‌یابد.
- ریتم حسی حرکتی ( $SMR^1$ ): SMR زیرمجموعه‌ای از باند مو (۸ تا ۱۳ هرتز) است که بر روی قشر حسی حرکتی برجسته است. در طول کارهای تصور حرکتی، همگام سازی (کاهش قدرت) SMR بر روی نیمکره مطابق با حرکت تصور شده مشاهده می‌شود. به‌عنوان مثال، تصور حرکت دست راست منجر به عدم همزمانی در قشر حسی حرکتی چپ می‌شود.
- باند بتا (۱۳-۳۰ هرتز): این باند فرکانسی با فعالیت‌های ذهنی و فیزیکی فعال‌تر (برنامه ریزی و اجرای حرکت) مرتبط است. فعالیت بتا در نواحی پیش‌پیشانی<sup>۲</sup> و مرکزی مغز بیشتر مشاهده می‌شود و با حالت‌های توجه، تمرکز و فعالیت‌های حرکتی در ارتباط است. افزایش فعالیت بتا معمولاً با فعالیت‌های حرکتی واقعی و تصویرسازی حرکتی همبستگی دارد (Alizadeh et al., 2023; Wang et al., 2005).

انواع مختلفی از فیلترها برای اعمال این فیلتر میان‌گذر وجود دارند که مهم‌ترین آنها، فیلتر Butterworth است. فیلتر Butterworth نوعی فیلتر پردازش سیگنال است که به‌گونه‌ای طراحی شده است که پاسخ فرکانسی آن در باند عبور، تاحدامکان صاف باشد (Yin et al., 2022).

---

<sup>1</sup> Sensorimotor Rhythm

<sup>2</sup> frontal

### ۳-۳\_ فیلترهای فضایی

فیلترهای فضایی برای بهبود سیگنال‌های EEG از طریق تکنیک‌های مختلف مورد استفاده قرار می‌گیرند. این تکنیک‌ها می‌توانند نویزهای ناخواسته را کاهش داده و سیگنال‌های عصبی مرتبط را تقویت کنند. الکترودهای EEG همچنین سیگنال‌های فیزیولوژیکی الکتریکی نامطلوب را از سیگنال‌های پلک چشم و عضلات گردن می‌گیرد. علاوه بر این مسائلی در رابطه با آرتیفکت‌های حرکت ناشی از حرکت کابل و جابه‌جایی الکترودها، هنگامی که فرد در حال حرکت است، وجود دارد. اما در نهایت هدف عمده این فیلترها source localization یا کاهش اثر تاری فضایی<sup>۱</sup> است. تاری فضایی به عنوان اثر فاصله بین حسگر و منابع سیگنال در مغز، به دلیل ناهمگنی بافت‌های بین نواحی مغز رخ می‌دهد (Yu et al., 2014).

سه فیلتر CAR، Low Laplacian و high Laplacian که در ادامه بررسی می‌شوند، شبیه به فیلترهای مشتق‌گیر عمل می‌کنند و هدف آنها حذف یک سری نویزها از سیگنال است. در کنار حذف نویز این فیلترها روی اطلاعات کانال‌ها (الکترودها) source localization را انجام می‌دهند؛ زیرا هر کانال ثبت داده، اطلاعات نواحی زیادی را دارد، با source localization در نهایت هر الکترودها تا حد ممکن اطلاعات مخصوص به ناحیه‌ای که ثبت انجام داده را خواهد داشت.

#### Common Average Reference (CAR)

این فیلتر برای هر کانال یا الکترودها، اختلاف آن کانال را از میانگین کانال‌های دیگر (فعالیت مشترک EEG) را محاسبه می‌کند که در نهایت تنها فعالیت هر EEG مجزا را در الکترودها مورد نظر باقی می‌گذارد (شکل 1) و به کاهش نویزهای مشترک بین تمام الکترودها کمک می‌کند. پتانسیل هر الکترودها بعد از فیلتر را می‌توان از طریق رابطه 1 به دست آورد که در آن  $x_i^{CAR}(t)$  خروجی فیلتر شده الکترودها،  $x_j(t)$  پتانسیل بین الکترودها و الکترودها مرجع و C تعداد کل الکترودها است (Yu et al., 2014).

$$x_i^{CAR}(t) = x_i(t) - \frac{1}{C} \sum_{j=1}^C x_j(t)$$

رابطه ۱

<sup>1</sup> spatial blurring

## Laplacian Filter

لاپلاسین یک اندازه گیری همسانگرد<sup>۱</sup> دوبعدی از مشتق دوم فضایی یک تصویر است. لاپلاسین اغلب بر روی تصویری اعمال می شود که ابتدا با چیزی شبیه به فیلتر صاف کننده گاوسی<sup>۲</sup>، صاف شده باشد تا حساسیت آن به نویز کاهش یابد، همچنین تأثیر خوبی در پردازش سیگنال دارد و در واقع تفاوت بین سیگنال یک الکتروود و میانگین سیگنال های اطراف آن را محاسبه می کند و با این کار منجر به بهبود رزولوشن فضایی سیگنال می شود. فیلتر لاپلاسی به خصوص در تصویرسازی حرکتی مفید است، زیرا فعالیت های عصبی مختص حرکات را به طور دقیق تری مشخص می کند. رابطه ۲ یک تقریب از این فیلتر را نشان می دهد که در آن  $x_i^{LAP}(t)$  سیگنال فیلتر شده الکتروود  $i$ ام است و  $x_i(t)$  پتانسیل الکتروود  $i$ ام در مقایسه با الکتروود مرجع است.  $w_{ij}$  یک وزن ثابت است که از طریق رابطه ۳ محاسبه می شود که در آن  $d_{ij}$  فاصله اقلیدسی از الکتروود  $i$  تا الکتروود  $j$  است و  $S_i$  مجموعه الکتروود های همسایگی الکتروود مرکزی  $i$  است. بسته به نوع فیلتر، مونتاژ الکتروود های همسایه می تواند اندازه کوچک و اندازه بزرگ باشد که در شکل ۱ نشان داده شده است. تعداد الکتروود های همسایه معمولاً ۴ است که در ردیف عمودی و افقی انتخاب می شوند و در آن  $x_i$  الکتروود مرکزی است (Yu et al., 2014).

$$x_i^{LAP}(t) = x_i(t) - \sum_{j \in S_i} w_{ij} x_j(t)$$

رابطه ۲


$$w_{ij} = \frac{1/d_{ij}}{\sum_{j \in S_i} 1/d_{ij}}$$

رابطه ۳

---

<sup>1</sup> isotropic

<sup>2</sup> Gaussian smoothing filter



شکل ۱- از سمت راست میانگین (برای فیلتر CAR)، مونتاژ همسایگی اندازه کوچک و اندازه بزرگ (برای فیلتر لاپلاسیان) (Yu et al. ۲۰۱۴).

### Principal Component Analysis (PCA)

به دلیل ناپایداری روش‌های جمع‌آوری سیگنال، سیگنال‌های جمع‌آوری شده روی پوست سر با بسیاری از سیگنال‌های مزاحم مخلوط شده و ابعاد بالایی دارند. تجزیه و تحلیل مؤلفه اصلی (PCA) یک روش ریاضی است که از یک تبدیل متعامد برای تبدیل مجموعه‌ای از مشاهدات متغیرهای احتمالاً همبسته به مجموعه‌ای از مقادیر متغیرهای خطی ناهمبسته به نام مؤلفه‌های اصلی استفاده می‌کند. این تکنیک می‌تواند ویژگی‌های مهم سیگنال را حفظ کرده و نویزهای غیرمرتبط را حذف کند که در نتیجه باعث ساده‌تر و کارآمدتر شدن پردازش بعدی می‌شود.

اگر  $x$  یک بردار به صورت  $x = (x_1, x_2, \dots, x_n)^T$  با توزیع تصادفی با میانگین  $\bar{x} = E(x)$  باشد. ماتریس کوواریانس آن با همان مجموعه داده به صورت  $\Sigma = E[(x - \bar{x})(x - \bar{x})^T]$  تعریف می‌شود که در آن  $\Sigma_{ij}$  همبستگی بین  $x_i$  و  $x_j$  را نشان می‌دهد. همچنین  $\sigma_{ii}$  نشان دهنده واریانس  $x_i$  است. ماتریس کوواریانس همیشه متقارن است. واریانس یک جزء نشان دهنده پراکندگی مقادیر مولفه در اطراف مقدار میانگین آن است. اگر دو جزء  $x_i$  و  $x_j$  از داده‌ها همبستگی نداشته باشند، کوواریانس آنها صفر است. از نمونه‌ای از بردارهای  $x_1, x_2, \dots, x_N$  می‌توان میانگین نمونه و ماتریس کوواریانس نمونه را به عنوان تخمین میانگین و ماتریس کوواریانس محاسبه کرد. از یک ماتریس متقارن مانند ماتریس کوواریانس، می‌توان یک مبنای متعامد را با یافتن مقادیر ویژه و بردارهای ویژه آن محاسبه کرد. بردارهای ویژه  $e_j (j = 1, \dots, k \leq n)$  و مقادیر ویژه مربوطه  $\lambda_j$  جواب‌های رابطه ۴ هستند.

$$\sum_i e_i = \lambda_i e_i$$

رابطه ۴

اگر بردار داده دارای  $n$  جزء باشد، معادله مشخصه از مرتبه  $n$  می‌شود. حل این مشکل تنها در صورتی آسان است که  $n$  کوچک باشد. حل مقادیر ویژه و بردارهای ویژه متناظر یک کار غیر پیش‌پاافتاده است و روش‌های مختلفی برای آن وجود دارد. این تبدیل به‌گونه‌ای تعریف می‌شود که اولین مؤلفه اصلی بیشترین واریانس ممکن را داشته باشد (یعنی تا آنجایی که ممکن است تغییرپذیری در داده‌ها را به خود اختصاص دهد) و هر مؤلفه بعدی با این محدودیت که متعامد به مؤلفه‌های قبلی باشد، بالاترین واریانس ممکن را دارد.

اگر میانگین نمونه و ماتریس کوواریانس یک مجموعه داده محاسبه شده باشد و  $A$  ماتریس انتقالی باشد که از بردارهای ویژه ماتریس کوواریانس به‌عنوان بردارهای هر سطر تشکیل شده است. با تبدیل یک مجموعه داده EEG به یک بردار، می‌توان خروجی  $y$  از روند کاهش ابعاد را به دست آورد.

$$y = A(x - \bar{x})$$

رابطه ۵

می‌توان بردار داده اصلی  $x$  را از  $y$  با استفاده از ویژگی یک ماتریس متعامد  $A^{-1} = A^T$  بازسازی کرد.

$$x = A^T y + \bar{x}$$

رابطه ۶

به‌جای استفاده از تمام بردارهای ویژه ماتریس کوواریانس، می‌توان داده‌ها را تنها بر حسب چند بردار پایه از پایه متعامد نشان داد. اگر ماتریسی که اولین بردارهای ویژه  $K$  را به‌عنوان ردیف دارد با  $A_K^T$  نشان داده شود، می‌توان تبدیلی مشابه با رابطه ۶ ایجاد کرد.

$$y = A_K(x - \bar{x})$$

رابطه ۷

$$x = A_K^T y + \bar{x}$$

رابطه ۸

در واقع با این کار بردار داده اصلی، روی محورهای مختصاتی که  $K$  بعد دارند، تصویر شده است و بردار با ترکیبی خطی از بردارهای پایه تبدیل می‌شود. این امر خطای میانگین مربعات (MSE) بین داده‌ها و این نمایش را با تعداد بردارهای ویژه داده شده به حداقل می‌رساند (Yu et al., 2014).

## Independent Component Analysis (ICA)

ICA یک روش پردازش سیگنال برای جداسازی سیگنال‌های مستقل از یک مجموعه سیگنال‌های مخلوط (به صورت خطی در چندین حسگر) است. به عنوان مثال، هنگام ثبت نوار مغزی (EEG) روی پوست سر، ICA می‌تواند آرتیفکت‌های موجود در داده‌ها را جدا کند (زیرا معمولاً مستقل از یکدیگر هستند). این تکنیک می‌تواند به جداسازی منابع سیگنال مختلف مانند فعالیت‌های عصبی، نویزهای عضلانی و چشم‌زدن کمک کند. ICA با تشخیص و حذف نویزهای غیرمرتبط، کیفیت سیگنال را بهبود می‌بخشد. برای اینکه بتوان ICA را برای سیگنال EEG بکار برد، لازم است که "سیگنال‌های منابع مختلف، از نظر آماری مستقل و غیرگوسی باشند". در این روش ابتدا سیگنال به مولفه‌های مستقل تجزیه می‌شود، سپس مولفه‌های مزاحم حذف شده و سیگنال اصلی با استفاده از مولفه‌های باقی‌مانده بازسازی می‌شود.

قبل از ICA، یک مرحله مهم، فیلتر کردن داده‌ها برای حذف نویز است که می‌تواند بر کیفیت عملکرد ICA تأثیر منفی بگذارد. یکی از پیش‌پردازش‌هایی که توسط اکثر الگوریتم‌های ICA انجام می‌شود سفید کردن داده‌ها است. به این معنی که هر گونه همبستگی در داده‌ها حذف شود، یعنی کانال‌های مختلف (ماتریس Q) مجبور به عدم همبستگی هستند. اگر به عنوان مثال، ۱۲۸ الکتروود EEG وجود داشته باشد. سیگنال ثبت شده در تمام الکتروودها در هر نقطه زمانی، یک نقطه داده را در یک فضای ۱۲۸ بعدی تشکیل می‌دهد. پس از سفید کردن داده‌ها، ICA ۱۲۸ محور را به منظور به حداقل رساندن گاوسی بودن برآمدگی بر روی تمام محورها، می‌چرخاند (بر خلاف PCA، محور نباید متعامد بماند). آنچه که مولفه‌های ICA نامیده می‌شود ماتریسی است که اجازه می‌دهد داده‌ها در فضای اولیه به یکی از محورهای یافت شده توسط ICA، تصویر شوند. در رابطه 9، W ماتریس وزن برای رفتن از فضای S به فضای X است. ماتریس وزن، تبدیل کامل از فضای اصلی است.

$$S = WX$$

رابطه ۹

سطرهای W برداری هستند که با آن می‌توان فعالیت یک جزء مستقل را محاسبه کرد. در نهایت برای بازگشت از فضای منبع S به فضای داده X از رابطه 10 استفاده می‌شود (ICA for Dummies - Arnaud Delorme, n.d.)

$$S = W^{-1}X$$

رابطه ۱۰



## Minimum Norm Estimation (MNE)

MNE یک تکنیک برای تخمین توزیع منابع عصبی در مغز بر اساس سیگنال‌های EEG است. این روش به تعیین نقاط فعال در مغز و تشخیص الگوهای خاص فعالیت مغزی کمک می‌کند. MNE می‌تواند به تجسم دقیق‌تر فعالیت‌های عصبی کمک کند و در نتیجه اطلاعات مفیدتری برای تحلیل‌های بعدی ارائه دهد.

ارتباط بین منابع فعال و اندازه‌گیری‌ها به صورت رابطه ۱۱ است، که در آن  $S(n_{\text{sources}} * \text{time points})$  ماتریس منابع است که  $M(n_{\text{channels}} * \text{time points})$  یعنی ماتریس اندازه‌گیری‌های EEG را تولید می‌کند.  $L(n_{\text{channels}} * n_{\text{sources}})$  ماتریس مربوط به لیدهای EEG و  $N(n_{\text{sources}} * \text{time points})$  نیز ماتریس نویز است.

$$M = LS + N$$

رابطه ۱۱

ماتریس لیدها نشان می‌دهد که چگونه هر منبع در اندازه‌گیری‌های هر حسگر، با توجه به مدل هدایت خاص سر و فضای منبع، مشارکت می‌کند. از آنجایی که تعداد منابع معمولاً بسیار بیشتر از تعداد حسگرها است، این ماتریس بسیار نامشخص است و بنابراین معکوس‌پذیر نیست. تخمین فعالیت منابع مستلزم تعریف عملگر معکوس  $W$  است:

$$\hat{S} = W^T M$$

رابطه ۱۲

که در آن  $\hat{S}$  منابع تخمین زده شده را نشان می‌دهد ( $n_{\text{sources}} * \text{time points}$ ).

MNE عملگر معکوس  $W$  را با جستجوی توزیعی از منابع با حداقل جریان ( $L_2$ -norm) محاسبه می‌کند که تخمینی از اندازه‌گیری‌ها ( $L\hat{S}$ ) که با داده‌های اندازه‌گیری شده ( $M$ ) مطابقت دارد، را می‌سازد. راه حل، یک موازنه بین نرم تخمین تنظیم شده<sup>۱</sup> منابع  $\lambda^2 \|\hat{S}\|^2$  و نرم کیفیت تناسب آنها با اندازه‌گیری‌های  $\lambda^2 \|M - L\hat{S}\|^2$  است. با فرض اینکه نویز  $N$  و قدرت منابع  $S$  به صورت یک توزیع نرمال با میانگین صفر و ماتریس کوواریانس  $Q$  و  $R$  به ترتیب، توزیع شده‌اند، یک شکل کلی از راه حل معکوس MNE را می‌توان به صورت زیر ارائه داد، که در آن  $\lambda$  پارامتر تنظیم است.

$$\hat{S} = \underset{S}{\operatorname{argmin}} \{ \|Q^{-1/2}(M - LS)\|^2 + \lambda^2 \|R^{-1/2}S\|^2 \}$$

رابطه ۱۳

<sup>۱</sup> regularized

عملگر معکوس  $W$  به صورت زیر تعریف می شود:

$$\hat{S} = RL^T(LRL^T + \lambda^2 Q)^{-1}$$

رابطه ۱۴

MNE فرض می کند که منابع توزیع مستقل و یکسان (iid) دارند که با یک ماتریس  $R$  در فرمول بالا مطابقت دارد. از طرف دیگر،  $R$  می تواند مفروضات آگاهانه تری (مکانی) را ترکیب کند و به اصطلاح MNE وزن دار را به دست آورد (Hincapié et al., 2016).

## ۴\_تکنیک‌های استخراج ویژگی

استخراج ویژگی از سیگنال‌های EEG (الکتروانسفالوگرافی) به معنای پردازش داده‌های خام EEG برای شناسایی و استخراج الگوها یا ویژگی‌های معناداری است که می‌توان از آن‌ها برای تحلیل‌های بیشتر مانند طبقه‌بندی، تشخیص یا تفسیر حالت‌های مغزی استفاده کرد. این مرحله بسیار مهم است زیرا سیگنال‌های خام EEG معمولاً پر از نویز و بسیار پیچیده هستند و تحلیل مستقیم آن‌ها دشوار است.

از نظر فنی، یک ویژگی نمایانگر یک خاصیت متمایز، یک اندازه‌گیری قابل تشخیص، و یک جزء عملکردی است که از بخشی از یک الگو به دست می‌آید. ویژگی‌های استخراج شده به این منظور به کار گرفته می‌شوند که از دست دادن اطلاعات مهمی که در سیگنال تعبیه شده‌اند را به حداقل برسانند. این ویژگی‌ها همچنین میزان منابع مورد نیاز برای توصیف درست یک مجموعه بزرگ از داده‌ها را کمتر می‌کنند. این امر برای حداقل کردن پیچیدگی پیاده‌سازی، کاهش هزینه پردازش اطلاعات و حذف نیاز احتمالی به فشرده‌سازی اطلاعات ضروری است.

به طور کلی، ویژگی‌ها بر اساس حوزه‌های (زمان، فرکانس و زمان-فرکانس) طبقه‌بندی می‌شوند. ویژگی‌ها معمولاً از سیگنال ضبط شده از یک الکتروود استخراج می‌شوند؛ اما، برخی از ویژگی‌ها وجود دارند که چندین الکتروود را ترکیب می‌کنند که این موارد نیز در این بخش پیاده‌سازی شده‌اند. با توجه به نمادگذاری به کار گرفته در (Jenke et al., 2014)  $\xi(t) \in \mathbf{R}^T$  برداری را نشان می‌دهد که حاوی سری زمانی از یک الکتروود است،  $T$  تعداد نمونه‌ها در  $\xi$  است. مشتق زمانی با  $\dot{\xi}(t)$  مشخص می‌شود. یک ویژگی از  $\xi(t)$  با  $x$  نشان داده می‌شود، ماتریس  $\mathbf{X} = [x_1, \dots, x_F]$  شامل تمام ویژگی‌ها از تمام نمونه‌ها است،  $x_i$  بردار یک ویژگی منفرد است و  $F$  تعداد ویژگی‌ها است.

### ۴-۱\_تکنیک‌های مختلف استخراج ویژگی

#### روش‌های حوزه زمان

از آنجایی که سیگنال‌های EEG تناوبی نیستند، استفاده از ویژگی‌های حوزه زمان در تحلیل EEG متداول نیست. با این حال، رویکردهای مختلفی وجود دارند که از چنین ویژگی‌هایی برای توصیف سیگنال‌های EEG جهت طبقه‌بندی استفاده می‌کنند. اولین مجموعه از ویژگی‌های این حوزه که در این کار پیاده‌سازی شده‌اند، معیارهای آماری سیگنال هستند. این معیارها به صورت زیر تعریف شده‌اند:

- Power:  $P_{\xi} = \frac{1}{T} \sum_{t=1}^T |\xi(t)|^2$
- Mean:  $\mu_{\xi} = \frac{1}{T} \sum_{t=1}^T \xi(t)$

- Standard Deviation:  $\sigma_{\xi} = \sqrt{\frac{1}{T} \sum_{t=1}^T (\xi(t) - \mu_{\xi})^2}$
- 1st difference:  $\delta_{\xi} = \frac{1}{T-1} \sum_{t=1}^{T-1} |\xi(t+1) - \xi(t)|$
- Normalized 1st difference:  $\bar{\delta} = \frac{\delta_{\xi}}{\sigma_{\xi}}$
- 2nd difference:  $\gamma_{\xi} = \frac{1}{T-2} \sum_{t=1}^{T-2} |\xi(t+2) - \xi(t)|$
- Normalized 2nd difference:  $\bar{\gamma}_{\xi} = \frac{\gamma_{\xi}}{\sigma_{\xi}}$

ویژگی  $P_{\xi}$  قدرت سیگنال یا انرژی مصرفی در واحد زمان را اندازه گیری می کند.  $\mu_{\xi}$  و  $\sigma_{\xi}$  ممان های آماری سیگنال هستند. اختلاف های اول و دوم توصیف می کنند که چگونه سیگنال در طول زمان تغییر می کند.  $\bar{\delta}$  نیز به عنوان چگالی طول نرمال شده شناخته می شود؛ این ویژگی شباهت های درون سیگنال EEG را کمی سازی می کند (Hernández et al., 2018).

سایر ویژگی های حوزه زمان که در این پژوهش پیاده سازی شده اند، ویژگی های (Hjorth) نامیده می شوند، که شامل سه معیار فعالیت Activity، تحرک Mobility و پیچیدگی Complexity می باشند. فعالیت که نشان دهنده واریانس سیگنال است، به صورت زیر تعریف می شود:

$$A_{\xi} = \frac{\sum_{t=1}^T (\xi(t) - \mu_{\xi})^2}{T}$$

رابطه ۱۵

تحرک با انحراف معیار مشتق اول سیگنال تعریف می شود، که از انحراف معیار دامنه به عنوان مرجع استفاده می کند و به صورت یک نسبت در واحد زمان بیان می شود:

$$M_{\xi} = \sqrt{\frac{\text{var}(\xi(t))}{\text{var}(\xi(t))}}$$

رابطه ۱۶

در نهایت، پیچیدگی تغییرات سیگنال را با استفاده از یک منحنی نرم به عنوان مرجع اندازه گیری می کند (Hernández et al., 2018):

$$C_{\xi} = \frac{M(\xi(t))}{M(\xi(t))}$$

رابطه ۱۷

## روش‌های حوزه فرکانس

تحلیل فوریه یکی از ابزارهای پایه برای پردازش سیگنال است. به همین دلیل، به طور گسترده برای توصیف سیگنال‌های EEG با اهداف مختلف استفاده می‌شود. برخی از محبوب‌ترین ویژگی‌ها در این حوزه، ویژگی‌های توان استخراج شده از باندهای فرکانسی مختلف هستند. این ویژگی‌ها با استفاده از طیف توان یا توان باند  $P(u)$  از  $\xi(t)$  محاسبه می‌شوند که به صورت  $P(u) = |F(u)|^2$  تعریف می‌شود، جایی که  $|F(u)|$  به طیف فوریه  $\xi(t)$  مربوط است. باندهای فرکانسی که سیگنال‌های EEG برای این ویژگی‌ها تجزیه می‌شوند در جدول ۱ آورده شده‌اند، توجه داشته باشید که محدوده باندها بین مطالعات مختلف کمی متفاوت است (Hernández et al., 2018).

جدول ۱- محدوده‌های باندهای فرکانسی معمول برای سیگنال‌های EEG

نام باند	محدوده
باند	
$\delta$	1 – 4
$\theta$	4 – 8
Slow $\alpha$	8 – 10
$\alpha$	8 – 12
$\beta$	12 – 30
$\gamma$	30 – 64

**روش تبدیل فوریه سریع ( $FFT^1$ ):** یک روش محاسباتی است که از ابزارها و متدهای ریاضی برای تجزیه و تحلیل داده‌های EEG استفاده می‌کند. ویژگی‌های سیگنال EEG از طریق برآورد چگالی طیفی توان ( $PSD^2$ ) محاسبه می‌شوند تا به طور انتخابی سیگنال‌های نمونه EEG را نمایش دهد. با این حال، چهار باند فرکانسی شامل امواج مشخص اصلی طیف EEG هستند. PSD توسط تبدیل فوریه داده‌های تقریب خودهمبستگی محاسبه می‌شود که توسط روش‌های غیر پارامتریک به دست می‌آید. یکی از این روش‌ها، روش ولج<sup>۳</sup> است. دنباله داده به پنجره بندی (ویندوئینگ) داده‌ها اعمال می‌شود و به دنباله‌های دوره‌های تغییر یافته تبدیل می‌شود. دنباله اطلاعات  $x_i(n)$  به صورت زیر تعریف می‌شود:

<sup>1</sup> Fast Fourier transform

<sup>2</sup> power spectral density

<sup>3</sup> Welch's method

$$x_i(n) = x(n + iD), n = 0, 1, 2, \dots, M - 1$$

$$\text{while } i = 0, 1, 2, \dots, L - 1;$$

رابطه ۱۸

$iD$  نقطه شروع دنباله نام باشد و  $L$  به طول  $2M$  نشان دهنده بخش‌هایی از داده است که تشکیل می‌شوند. نتایج تقریبی خروجی، دوره‌های دوره‌ای خروجی را به صورت زیر تولید می‌کنند:

$$\tilde{P}_{xx}^{(i)}(f) = \frac{1}{MU} \left| \sum_{n=0}^{M-1} x_i(n) w(n) e^{-j2\pi f n} \right|^2$$

رابطه ۱۹

که در اینجا، در تابع پنجره،  $U$  عامل نرمال‌سازی توان می‌باشد و برابر است با:

$$U = \frac{1}{M} \sum_{n=0}^{M-1} w^2(n)$$

رابطه ۲۰

که در آن  $w(n)$  تابع پنجره است. میانگین این دوره‌های تغییر یافته، طیف توان ولج را به شکل زیر ارائه می‌دهد:

$$P_{xx}^W = \frac{1}{L} \sum_{i=0}^{L-1} \tilde{P}_{xx}^{(i)}(f)$$

رابطه ۲۱

## روش‌های حوزه زمان-فرکانس

روش‌های حوزه زمان-فرکانس، روش‌هایی هستند که از ترکیب اطلاعات زمانی و فرکانسی در تجزیه و تحلیل سیگنال‌ها استفاده می‌کنند. این روش‌ها برای مطالعه سیگنال‌هایی که ویژگی‌های فرکانسی آن‌ها با زمان تغییر می‌کند، بسیار مفید هستند که در ادامه به توضیح یکی از روش‌های معمول این حوزه می‌پردازیم:

**روش تبدیل موجک ( $WT^1$ ):** یک ابزار بسیار مهم در پردازش سیگنال‌های پزشکی مانند

سیگنال EEG است. این تبدیل قابلیت فشرده‌سازی داده‌های پیچیده زمانی را دارد و اطلاعات مهم را حفظ می‌کند، همچنین انعطاف‌پذیری در نمایش زمان-فرکانسی ارائه می‌دهد. با توجه به غیرپایداری سیگنال‌های EEG، استفاده از تبدیل WT برای استخراج ویژگی‌ها از داده‌های خام بسیار مناسب است. این روش امکان تجزیه و تحلیل دقیق‌تری از ویژگی‌های سیگنال را فراهم می‌کند و بهترین روش برای تحلیل سیگنال‌های غیرپایدار مانند EEG است.

از آنجایی که تبدیل موجک اجازه استفاده از پنجره‌های با اندازه متغیر را می‌دهد، این روش یک روش انعطاف‌پذیرتر برای نمایش زمان-فرکانس یک سیگنال فراهم می‌کند. برای دستیابی به رزولوشن پایین فرکانسی دقیق‌تر، از پنجره‌های طولانی زمانی تبدیل موجک استفاده می‌شود؛ در مقابل، برای به دست آوردن اطلاعات فرکانس بالا، از پنجره‌های کوتاه زمانی استفاده می‌شود.

تبدیل موجک فقط دارای ساختار چند مقیاسی می‌باشد. این روش فقط ادامه‌ای از روش تبدیل فوریه است و به منظور حل مشکلات سیگنال‌های غیرایستا مانند EEG به وجود آمده است. در روش تبدیل موجک، سیگنال اصلی EEG توسط بلوک‌های ساختمانی ساده که به موجک‌ها شناخته می‌شوند، نمایش داده می‌شود. دو روش برای تبدیل موجک وجود دارد که عبارتند از:

- **تبدیل موجک پیوسته ( $CWT^2$ ):** این روش به صورت زیر تعریف می‌شود:

$$CWT(a, b) = \int_{-\infty}^{\infty} x(t) \psi_{a,b}^*(t) dt$$

رابطه ۲۲

که در آن  $x(t)$  نمایانگر EEG بدون پردازش است،  $a$  به تغییر مقیاس اشاره دارد و  $b$  عامل ترجمه را نشان می‌دهد. تابع  $\psi_{a,b}(t)$  متقارن مختلط است و می‌توان آن را به صورت زیر محاسبه کرد:

$$\psi_{a,b}(t) = \frac{1}{\sqrt{|a|}} \psi\left(\frac{t-b}{a}\right)$$

رابطه ۲۳

که در  $\psi(t)$  نمایانگر موجک است.

<sup>1</sup> Wavelet Transform

<sup>2</sup> Continuous Wavelet Transform

نقطه ضعف اصلی این روش این است که پارامتر اندازه‌گیری  $a$  و پارامتر ترجمه  $b$ ، به صورت پیوسته تغییر می‌کنند. بنابراین، ضرایب موجک برای تمام مقیاس‌های موجود پس از محاسبه انرژی زیادی را مصرف می‌کنند و اطلاعات به درد نخور زیادی تولید می‌کنند.

- تبدیل موجک گسسته ( $DWT^1$ ):

برای رفع مشکلات (CWT)، تبدیل موجک گسسته (DWT) بر مبنای نمایش چند مقیاسه ویژگی تعریف شده است. هر مقیاس در نظر گرفته شده نشان‌دهنده ضخامت منحصر به فردی از سیگنال EEG است تجزیه چند مقیاسه داده‌های EEG خام  $x(n)$  در شکل ۳ نشان داده شده است. هر مرحله شامل دو فیلتر دیجیتال،  $g(n)$  و  $h(n)$ ، و دو downsampler به اندازه ۲ می‌باشد. موجک  $g(n)$  از نوع فیلتر بالاگذر است، در حالی که  $h(n)$  از نوع پایین‌گذر می‌باشد.

همانطور که در شکل ۲ نشان داده شده است، خروجی هر مرحله جزئیات سیگنال  $D$  و تقریب سیگنال  $A$  را فراهم می‌کند، که آخرین مورد، ورودی مرحله بعدی می‌شود. تعداد مراحل که موجک به آن‌ها تجزیه می‌شود، با توجه به مؤلفه داده‌های EEG با فرکانس غالب انتخاب می‌شود.

رابطه بین ویژگی‌های WT و فیلتر  $h$  یا همان فیلتر پایین‌گذر، می‌تواند به شکل زیر نمایش داده شود:

$$H(z)H(z^{-1}) + H(-z)H(-z^{-1}) = 1$$

رابطه ۲۴

در اینجا،  $H(z)$  نمایانگر تبدیل  $z$  فیلتر  $h$  است.

تبدیل  $z$  مکمل فیلتر پایین‌گذر نیز به صورت زیر تعریف می‌شود:

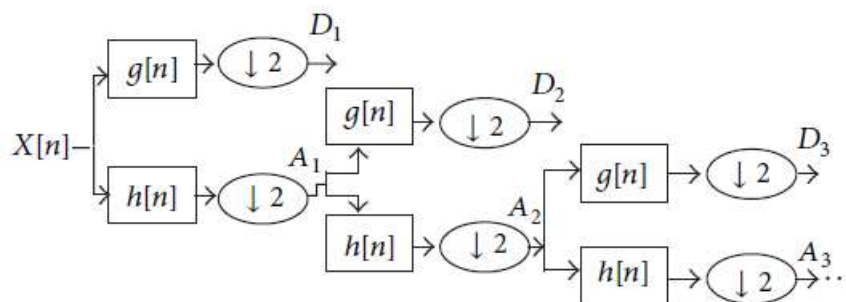
$$G(z) = zH(-z^{-1})$$

رابطه ۲۵

توصیف دقیق ویژگی‌های بخش‌های سیگنال در یک دامنه فرکانس مشخص و ویژگی‌های زمانی محلی، مزایای زیادی دارد که نیاز محاسباتی و حافظه بالای اجرای مبتنی بر روش کانوولوشنی معمولی DWT را تغییر می‌دهد (Al-Fahoum & Al-Fraihat, 2014).

<sup>1</sup> Discrete Wavelet Transform





شکل ۲- عملیات تجزیه تبدیل موجک (DWT)

## روش‌های فضایی

**الگوریتم CSP:** الگوریتم (CSP1) یکی از روش‌های مهم برای استخراج ویژگی‌ها از سیگنال‌های EEG است که در بسیاری از برنامه‌های رابط مغز-کامپیوتر (BCI) مورد استفاده قرار می‌گیرد. این الگوریتم برای تفکیک الگوهای فعالیت مغزی مختلفی که در سیگنال‌های EEG مشاهده می‌شود، بسیار موثر است. الگوریتم CSP یک روش تحلیل مهندسی برای توصیف روابط مختلف بین داده‌های ورودی به صورت خطی و غیرخطی است.

بخش استخراج ویژگی‌ها در الگوریتم CSP شامل چند مرحله مهم است:

۱. **برآوردسازی<sup>۲</sup>:** داده‌های EEG پس از پیش‌پردازش به وسیله فیلترهای CSP برآورد می‌شوند. این کار باعث تبدیل داده‌ها به فضای ویژگی جدیدی می‌شود که ویژگی‌های مهم تر و برجسته‌تر را نشان می‌دهد.
۲. **انتخاب ویژگی:** در این مرحله، ویژگی‌های مهم و کلیدی از داده‌های برآورد شده انتخاب می‌شوند. معمولاً ویژگی‌هایی که بیشترین توانایی تمیزدهی بین دو کلاس مختلف را دارند، انتخاب می‌شوند.
۳. **نمایش ویژگی:** ویژگی‌های استخراج شده برای هر نمونه‌ی داده به عنوان نقاط داده‌ای در یک فضای ویژگی می‌توانند نمایش داده شوند. این نمایش معمولاً به منظور بررسی توزیع و تفکیک‌پذیری کلاس‌ها در فضای ویژگی استفاده می‌شود.

<sup>1</sup> Common Spatial Patterns

<sup>2</sup> Projection

با استفاده از این مراحل، الگوریتم CSP به طور موثر ویژگی‌هایی از سیگنال‌های EEG استخراج می‌کند که اطلاعات مفیدی را در مورد فعالیت مغزی مورد نظر فراهم می‌کند و قادر است این ویژگی‌ها را به صورتی که قابلیت تمیزدهی خوبی را داشته باشند، نمایش دهد. در ادامه می‌خواهیم با جزئیات بیشتری از نحوه عملکرد این ویژگی برداریم:

الگوریتم CSP یک روش فیلترینگ فضایی است که برای یافتن جهت بهینه‌ی برآورد در فضا به کار می‌رود، به گونه‌ای که واریانس سیگنال برآورد شده از یک نوع در این جهت به حداکثر می‌رسد، و واریانس برآورد شده سیگنال نوع دیگر به حداقل می‌رسد. الگوریتم CSP ابتدا با اعمال تجزیه مقادیر ویژه بر روی ماتریس، ماتریس whitening را بدست می‌آورد، سپس از روش whitening برای انجام عملیات whitening بر روی دو ماتریس کوواریانس استاندارد استفاده می‌کند، و جهت برآورد سازی که می‌تواند تفاوت واریانس بین دو ماتریس را به حداکثر برساند را پیدا می‌کند. این روش به صورت زیر است:

سیگنال EEG به صورت یک ماتریس  $E$  با ابعاد  $N \times T$  نمایش داده می‌شود، که اینجا  $N$  تعداد کانال‌ها و  $T$  نقاط نمونه‌برداری برای هر کانال است. ماتریس کوواریانس با نرمال‌سازی داده‌های EEG به صورت زیر به دست می‌آید:

$$C = \frac{EE^T}{\text{tr}E EE^T}$$

رابطه ۲۶

با محاسبه ماتریس کوواریانس میانگین هر آزمایش و ماتریس کوواریانس فضایی که نمایانگر بخش چپ و راست مغز است، ماتریس تفاوت به دست می‌آید. ماتریس کوواریانس فضایی نهایی به شکل زیر است:

$$C_C = C_l + C_r$$

رابطه ۲۷

بردار ویژه ماتریس، متناظر با مقدار ویژه آن است که مقادیر ویژه به ترتیب نزولی قرار داده شده‌اند. در مرحله بعد روش تجزیه اجزای اصلی (PCA) برای محاسبه تبدیل whitening اعمال می‌شود:

$$P = \sqrt{\lambda_c^{-1} U_c^T}$$

رابطه ۲۸

سپس جمع ماتریس کوواریانس به صورت زیر محاسبه می‌شود:

$$S_1 = PC_1P^T, S_r = PC_rP^T$$

رابطه ۲۹

با بردار ویژه مشترک B، سیگنال EEG تمیز شده<sup>۱</sup> روی بردارهای ویژه ستون‌های جلو و عقب m از بردار ویژه B برآورد می‌شود تا ویژگی طبقه‌بندی بهینه را بدست آورد. سپس، ماتریس برآورد می‌تواند برای تبدیل داده‌های EEG به  $Z=WE$  استفاده شود. در نهایت، سیگنال برآورد شده ( $p=1\dots,2m$ ) به عنوان مقدار ویژه پس از انجام تغییرات زیر قرار می‌گیرد (Feng et al., 2019).

$$f_p = \log \left( \frac{\text{var}(Z_p)}{\sum_{i=1}^{2m} \text{var}(Z_i)} \right)$$

رابطه ۳۰

---

<sup>۱</sup> bleached

- Al-Fahoum, A. S., & Al-Fraihat, A. A. (2014). Methods of EEG Signal Features Extraction Using Linear Analysis in Frequency and Time-Frequency Domains. *ISRN Neuroscience*, 2014, 1–7. <https://doi.org/10.1155/2014/730218>
- Alizadeh, N., Afrakhteh, S., & Mosavi, M. R. (2023). Multi-Task EEG Signal Classification Using Correlation-Based IMF Selection and Multi-Class CSP. *IEEE Access*, 11, 52712–52725. <https://doi.org/10.1109/ACCESS.2023.3274704>
- Blankertz, B., Muller, K.-R., Krusienski, D. J., Schalk, G., Wolpaw, J. R., Schlogl, A., Pfurtscheller, G., Millan, J. R., Schroder, M., & Birbaumer, N. (2006). The BCI competition III: Validating alternative approaches to actual BCI problems. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 14(2), 153–159.
- Fatourechi, M., Bashashati, A., Ward, R. K., & Birch, G. E. (2007). EMG and EOG artifacts in brain computer interface systems: A survey. *Clinical Neurophysiology*, 118(3), 480–494.
- Fazli, S., Popescu, F., Danóczy, M., Blankertz, B., Müller, K.-R., & Grozea, C. (2009). Subject-independent mental state classification in single trials. *Neural Networks*, 22(9), 1305–1312.
- Feng, G., Hao, L., & Nuo, G. (2019). Feature Extraction Algorithm based on CSP and Wavelet Packet for Motor Imagery EEG signals. *2019 IEEE 4th International Conference on Signal and Image Processing, ICSIP 2019*, 798–802. <https://doi.org/10.1109/SIPROCESS.2019.8868635>
- He, H., & Wu, D. (2019). Transfer learning for brain–computer interfaces: A Euclidean space data alignment approach. *IEEE Transactions on Biomedical Engineering*, 67(2), 399–410.
- Hernández, D. E., Trujillo, L., Z-Flores, E., Villanueva, O. M., & Romo-Fewell, O. (2018). Detecting Epilepsy in EEG Signals Using Time, Frequency and Time-Frequency Domain Features. *Studies in Systems, Decision and Control*, 143, 167–182. [https://doi.org/10.1007/978-3-319-74060-7\\_9](https://doi.org/10.1007/978-3-319-74060-7_9)
- Hincapié, A. S., Kujala, J., Mattout, J., Daligault, S., Delpuech, C., Mery, D., Cosmelli, D., & Jerbi, K. (2016). MEG connectivity and power detections with minimum norm estimates require different regularization parameters. *Computational Intelligence and Neuroscience*, 2016. <https://doi.org/10.1155/2016/3979547>
- ICA for dummies - Arnaud Delorme*. (n.d.). Retrieved May 23, 2024, from [https://arnauddelorme.com/ica\\_for\\_dummies/](https://arnauddelorme.com/ica_for_dummies/)
- Jenke, R., Peer, A., & Buss, M. (2014). Feature extraction and selection for emotion recognition from EEG. *IEEE Transactions on Affective Computing*, 5(3), 327–339. <https://doi.org/10.1109/TAFFC.2014.2339834>

- Jeunet, C., Jahanpour, E., & Lotte, F. (2016). Why standard brain-computer interface (BCI) training protocols should be changed: an experimental study. *Journal of Neural Engineering*, 13(3), 36024.
- McFarland, D. J., & Wolpaw, J. R. (2011). Brain-computer interfaces for communication and control. *Communications of the ACM*, 54(5), 60–66.
- Munzert, J., Lorey, B., & Zentgraf, K. (2009). Cognitive motor processes: the role of motor imagery in the study of motor representations. *Brain Research Reviews*, 60(2), 306–326.
- Neuper, C., & Pfurtscheller, G. (2010). Neurofeedback training for BCI control. *Brain-Computer Interfaces: Revolutionizing Human-Computer Interaction*, 65–78.
- Pfurtscheller, G., & Neuper, C. (2001). Motor imagery and direct brain-computer communication. *Proceedings of the IEEE*, 89(7), 1123–1134.
- Sharma, N., Pomeroy, V. M., & Baron, J.-C. (2006). Motor imagery: a backdoor to the motor system after stroke? *Stroke*, 37(7), 1941–1952.
- Wang, Y., Gao, S., & Gao, X. (2005). Common spatial pattern method for channel selection in motor imagery based brain-computer interface. *Annual International Conference of the IEEE Engineering in Medicine and Biology - Proceedings*, 7 VOLS, 5392–5395. <https://doi.org/10.1109/IEMBS.2005.1615701>
- Yin, X., Xu, B., Jiang, C., -, al, Zhang, Y., Qiu, S., He -, H., Dharan, B. M., Kumar, K. T., & Deepa Beeta, T. (2022). Signal Processing for Hybrid BCI Signals. *Journal of Physics: Conference Series*, 2318(1), 012007. <https://doi.org/10.1088/1742-6596/2318/1/012007>
- Yu, X., Chum, P., & Sim, K. B. (2014). Analysis the effect of PCA for feature reduction in non-stationary EEG based motor imagery of BCI system. *Optik*, 125(3), 1498–1502. <https://doi.org/10.1016/J.IJLEO.2013.09.013>